

내가 발견한거

#1. 문제 정의

주어진 문제는 과거의 위치 좌표 시계열 데이터를 바탕으로 미래의 특정 시점 위치를 추정하는 함수 f 를 찾는 것입니다.

관측 시간 간격: $\Delta t = 40 \text{ ms}$

관측 시점: $t \in \{-400, -360, \dots, -40, 0\}$

총 관측 횟수: $N = 11$


관측된 3차원 좌표: $X_t = (x_t, y_t, z_t) \in \mathbb{R}^3$

모델의 입력 텐서 I 와 타겟 변수 Y 는 다음과 같이 정의됩니다.

$$I = [X_{-400}, X_{-360}, \dots, X_0]^T \in \mathbb{R}^{11 \times 3}$$


$$Y = X_{+80} \in \mathbb{R}^3$$

우리의 목표는 파라미터 θ 를 가지는 예측 모델 $f_\theta(I) = \hat{Y}$ 를 학습하여 실제 위치 Y 와의 3차원 거리 오차가 1cm 이내로 들어오게 하는 것입니다.



데이터의 마지막 시점, 전진방향으로 2가지 분포가 보인다.

$t=0$, $t=-40$, $t=-80$ 을 이용해 구한 비틀림 즉 k 는 $\log$ 를 씌울시 정규분포를 보인다.



X축: 현재 스칼라 속력 ($\|v\|$)

코드에서 현재 시점 $t = 0$ 을 기준(위치 p_0)으로 바로 직전 과거인 $t = -40\text{ms}$ (위치 $p_{-40\text{ms}}$) 사이의 위치 변화량을 시차 $\Delta t = 0.04\text{s}$ 로 나누어 속도 벡터 v 를 구했습니다.

$$v = \frac{p_0 - p_{-40\text{ms}}}{\Delta t}$$

이 벡터의 크기(L2 Norm)인 $\|v\|$ 를 구한 값이 X축이 됩니다.

Y축: 미래 변위 (Future Displacement)

딥러닝 모델이 예측해야 하는 타겟값으로, 현재 시점 $t = 0$ 에서 미래 $t = +80\text{ms}$ 시점의 위치 $p_{+80\text{ms}}$ 까지의 직선거리를 계산했습니다.

$$\text{Future Displacement} = \|p_{+80\text{ms}} - p_0\|$$


이 거리가 Y축이 됩니다.

파란색 직선 (Trendline)


Plotly의 `trendline="ols"` 옵션에 의해 생성된 선으로, 수많은 점들 사이를 통과하는 최소제곱법 (Ordinary Least Squares) 기반의 선형 회귀 직선입니다. 두 변수 간의 선형적 경향성을 보여줍니다.

심지어 파란색 직선은 기울기가 거의 0.8이다. 데이터를 가장 잘 설명하는 “선”은 등속도 였다는 것이다.

로컬 프레네(T-N-B) 변위 분포 비교 (Interactive)
과거 80ms 중강 분포 (Historical)





마지막 시점 정답 분포 (Ground Truth)




· F
· F
· C
· C


과거 분포를 살펴봐도, T가 0.1 이상인 곳에서 새로운 분포를 이루고 있음을 확인할 수 있다.





$\mathbf{v} \cdot \mathbf{a}$ 값에 따른 분포 (“가속도 화살표가 속도 화살표와 같은 방향을 거두고 있는가?” 그걸 수학적으로 계산해 주는 도구가 바로 두 벡터의 내적($\vec{v} \cdot \vec{a}$))





FP 가 FN에 비해서 상당히 count가 많다는 것을 알수 있다.
 진행방향에 대해서, 감속하다가 가속하는것은 어렵지만,
 가속하다가 감속하는 것은 쉽다는 의미.


곤충 비행의 동역학적 비대칭성 (가속보다 감속이 쉽다)

모기처럼 질량이 극도로 작은 미소 곤충은 공기 저항(Drag)의 지배를 강하게 받아. 뉴턴의 운동방정식으로 보면 전진 가속을 하려면 엄청난 근육 힘으로 양력을 쥐어짜야 하지만, 감속을 하거나 방향을 틀 때는 날개 각도만 살짝 비틀어도 공기 저항 때문에 운동 에너지가 순식간에 삭제되지.

즉, 가속 상태($v \cdot a > 0$)에 있던 모기가 다음 80ms라는 찰나의 순간에 돌발적으로 급브레이크를 밟거나 선회(Turn) 기동으로 꺾어버릴 확률이 물리적으로 매우 높아.

라고 제미니가 말한다.

그렇다면 FP는 상당한 NB방향 이동을 보이지 않을까?




정말로 그렇다!

False Positive 그룹의 바이올린 개형을 보면, 횡방향 변위 수치인

$$d_{\text{lateral}} = \sqrt{\Delta N^2 + \Delta B^2}$$

의 중앙값(내부 점선)과 사분위수 분산이 다른 세 그룹에 비해 압도적으로 높은 위치에 형성되어 있는 게 눈에 확 들어올 거야. 몸통 자체가 위쪽 공간으로 부풀어 올랐고, 분포의 끝단도 최고 임계점인 **0.11** 부근까지 길게 늘어져 있지.

반면 에러 없이 예측이 적중한 **True Positive** 그룹은 대부분의 데이터가 **0.01** 이하의 바닥 평면에 극도로 슬림하게 밀착되어 있어.



속력이 작을 수록, FN : $v \cdot a < 0$ (과거 시점 감속), 실제로는 가속, 증가
 속력이 클수록, 모기가 물리적으로 낼 수 있는 속도에 제한됨. $v \cdot a > 0$ 지만 과거시점
 진행방향으로는 감속으로 찍힌 값들 증가

거의 항상 일정하게 $v \cdot a > 0$ 지만, 실제로는 T방향 이동이 등속도보다 적은 데이터 많음.

전 구간에 상시 존재하는 **FP** (선회의 흔적)

중간 속도 구간(0.3 ~ 1.2 m/s)을 가로질러 봐도 핑크색 바(FP)의 지분이 항상 20%에서 37% 사이를 완벽하게 유지하고 있어.

- 물리적 의미: 모기는 직선 주로만 달리는 레이싱카가 아니라, 공중에서 3차원으로 화려하게 제어를 꺾는 생명체라는 증거야.
- 직전까지 아무리 기분 좋게 전진 가속을 밟고 있었더라도, 다음 80ms라는 찰나의 순간에 획 방향을 틀어버리는 급선회 기동(NB 방향 이동)을 모든 속도 영역에서 아주 빈번하게 수행하고 있다는 뜻이지. 앞서 바이올린 플롯에서 FP의 NB 변위가 치솟았던 이유가 여기서 완벽하게 결합해.

$$\vec{a} = a_t \vec{T} + a_n \vec{N}$$

True Positive (순수 전진 가속)

TP는 모기가 머리 방향 그대로 직선 풀 액셀을 밟은 상태야. 즉, 방향 전환이 거의 없으므로 법선 방향 힘인 $a_n \rightarrow 0$ 이 되지. 위 수식에 대입하면 속력이 존재하는 한 $\kappa \rightarrow 0$ 으로 수렴하게 돼.


False Positive (급선회 기동)

FP는 전진 가속 중인 줄 알았으나 실제로는 옆이나 위아래로 틀어버린 상태야. 방향을 급격하게 바꾸려면 강력한 횡방향 원심력(a_n)이 개입해야만 하므로, κ 값이 폭발적으로 상승하게 되지.

즉, 동일하게 $v \cdot a > 0$ 이라 하더라도, **TP**는 카파가 극도로 낮고, **FP**는 카파가 극도로 높다는 명확한 기하학적 차별성이 성립해.

피쳐 1: 가속도 배분 각도 ($\tan \theta$ 혹은 기하 비율)


$$\text{Ratio} = \frac{a_n}{a_t} = \frac{\kappa \|\vec{v}\|^3}{\vec{v} \cdot \vec{a}}$$



1.3 이상 즉 속도가 한계에 달했을 때 유의미한 피쳐다.

근데 시계열로 봐보자. 마르코프만 볼 피쳐가 아니다. 가속도의 배분이 시계열에서 어떻게 달라졌는지도 중요하다.

일단 3개의 과거 스텝만 봐보자.



Graph 1 해석: 3-Step 가속도 배분 비율 궤적

Y축의 값은 우리가 정의한 가속도 배분 비율인 $\log_{10}(a_n/a_t)$ 의 평균값과 95% 신뢰구간(CI)의 스펙트럼이야. 이 궤적은 모기가 현재 가속 판단 시점(t)에 도달하기까지 과거 3스텝 동안 에너지를 어떻게 배분하며 걸어왔는지 보여줘.


- True Positive (진한 빨간색 라인)**
 시간이 흐를수록 ($t-2 \rightarrow t-1 \rightarrow t$) 레시오 수치가 대략 $0.21 \rightarrow 0.16 \rightarrow 0.12$ 로 지속적으로 감소하는 우하향 곡선을 그려.
 이는 분모인 접선 가속도(a_t) 대비 분자인 법선 가속도(a_n)의 비중이 시간이 갈수록 줄어들고 있음을 뜻해. 즉, 모기가 측면 요동을 스스로 억제하고 순수하게 현재 진행 방향 기저 벡터인 T 축으로 온 힘을 집중하며 직선 주로를 타고 순항 가속하고 있다는 명백한 증거야.
- False Positive (연한 분홍색 라인)**
 반대로 $t-2$ 시점의 대략 0.45에서 시작해서 현재 시점 t 에 이르러서는 0.70 부근까지 가파르게 우상향하며 치솟는 궤적을 보여주지.
 현재 시점 t 에서 단순 내적값 $\vec{v} \cdot \vec{a} > 0$ 이 계산되어 시스템은 가속할 것으로 예측(Positive)했어. 하지만 실제 기하학적 내막은 이미 2스텝 전부터 방향 전환 힘(a_n)의 비중이 비정상적으로 높았고, 현재 그 선회 모멘텀이 정점에 달한 상태야.
 결국 추진 에너지가 전진(T)이 아닌 선회(N, B) 평면으로 전부 쏠려 미래 변위가 급감할 것(False)을 과거 3스텝의 누적 기울기가 시계열적으로 경고하고 있었던 거지.

피쳐 2: $\log(\kappa)$ 의 이동 평균 편차 (시간차 징후 포착)
 $\Delta \log(\kappa)_t = \log(\kappa_t) - \log(\kappa_{t-1})$

원가 피쳐1의 3시계열 한거랑 매우 중복적인거 같다는 느낌이 듬.

마지막 의문
 어떻게 NB방향 이동의 방향을 알 수 있게 하지?

v와 a의 각도 파이



왼쪽 D_T (종방향) 그래프를 보면 속력 성분이 미래 변위의 크기를 선형적으로 아주 잘 결정해 주고 있습니다. 노란색 고속 데이터가 상단에 예쁘게 띠를 형성하므로, 모델은 직진 성분(D_T) 예측에는 어려움이 없습니다.

문제는 가운데와 우측의 D_N, D_B 영역입니다. $\cos \phi \approx 0$ (순수 선회 진입)이면서 속력이 높을 때(노란색 점들), 미래 변위가 0을 중심으로 위아래로 거대하게 발산합니다.

하지만 이게 과거의 v와 a만 가지고도 파이가 0일때 NB방향 변위가 커진다는 힌트를 모델에 줄수 있다!!

프레네의 한계

이것은 Frenet 프레임의 수학적 정의가 가진 본질적인 한계 때문입니다. 현재 시점 $t=0$ 에서 가속도 벡터 $\vec{a}$ 는 정의상 항상 $+N$ 방향으로 정렬됩니다. 즉, 좌표계 자체가 모기가 현재 꺾고 있는 방향을 기준 축으로 삼아 자동으로 계속 회전하며 쫓아갑니다.

로컬 프레임이 이미 현재의 선회 방향 성분을 '흡수'하여 기준점(0)으로 만들어버렸기 때문에, $t > 0$ 인 미래에 모기가 이 선회를 더 강하게 유지할지($+N$ 공간) 아니면 반대 방향으로 풀며 복원할지($-N$ 공간)는 $t=0$ 에서의 순간적인 로컬 미분량(v, a, j)만으로는 구별할 수 없는 등방성 확률 분포로 남게 되는 것입니다.

대회 마무리 정리

모기 비행 궤적 예측대회 최종 분석 보고서

본 보고서는 과거의 3차원 위치 좌표 시계열 데이터를 바탕으로 모기의 미래 비행 궤적을 예측하는 대회에 대한 진행 과정, 시행착오, 탐색적 데이터 분석을 통한 가설 검증, 핵심 구현 코드 설명, 그리고 동료의 아이디어로 극복한 최종 성과와 본질적인 한계점들을 체계적으로 정리한 문서입니다.

1. 문제 정의 및 데이터 구조 (Problem Definition)

주어진 과제는 이전에 관측된 모기의 3차원 위치 좌표를 입력받아, 미래 특정 시점의 위치를 정확하게 추정하는 예측 함수 f 를 설계하는 것입니다.

1.1 시간 및 공간 정의

- 관측 시간 간격: $\Delta t = 40 \text{ ms}$
- 관측 시점 시계열: $t \in \{-400, -360, \dots, -40, 0\}$ (총 관측 횟수 $N = 11$)
- 관측 공간 좌표: $X_t = (x_t, y_t, z_t) \in \mathbb{R}^3$

1.2 입력 및 타겟 데이터 구조

모델의 입력 텐서 I 와 타겟 변수 Y 는 다음과 같이 정의됩니다.

$$I = [X_{-400}, X_{-360}, \dots, X_0]^T \in \mathbb{R}^{11 \times 3} \quad Y = X_{+80} \in \mathbb{R}^3$$

최종 목표는 파라미터 θ 를 가지는 예측 모델 f_{θ} 를 학습하여, 아래와 같이 정의되는 유클리드 거리 오차 E 를 최소화하는 것입니다.

$$E = \|Y - f_{\theta}(I)\|_2 < 1 \text{ cm}$$

2. 초기 아이디어와 물리적 시행착오 (Early Hypotheses & Trials)

대회 초기에 고안했던 접근법들과 데이터를 다루며 깨닫게 된 기하학적 정정 사항들은 다음과 같습니다.

2.1 물리적 궤적 후보군 생성 (Physical Trajectory Templates)

모델이 학습 과정에서 임의의 좌표를 예측하여 노이즈에 과적합(Overfitting)되는 것을 방지하기 위해, 고전 역학에 기반한 이산적인 타당한 미래 위치 후보 집합 $C = \{C_1, C_2, \dots, C_K\}$ 를 사전에 정의하여 템플릿화하는 방안을 설계했습니다.

- 기본 관성 후보 (Constant Velocity):
 $C_{\text{base}} = X_0 + \vec{v} \cdot 2\Delta t$

- 약한 가속 및 제동 후보 (예: 90% 속도 유지):

$$C_{\text{frenet_par090}} = X_0 + (0.9\vec{v}) \cdot 2\Delta t$$
- 방향 전환 (Turn) 후보 (법선 방향 힘 개입):

$$C_{\text{turn_pos}} = C_{\text{base}} + \alpha \vec{N}$$
- 시스템 지연 (Latency) 보정 후보 (시간 축 확장):

$$C_{\text{latency_long}} = X_0 + \vec{v} \cdot (2\Delta t + \delta)$$

이러한 물리적 템플릿들을 조합하여 약 10개에서 20개의 후보 위치를 생성하고 이를 바탕으로 투표하는 방식을 생각했으나, 연구가 진행됨에 따라 정교하게 튜닝된 등속도(Constant Velocity) 기반의 연속적 예측 모델이 이산 후보군 분류 방식보다 훨씬 안정적이며 우수한 일반화 성능을 보임을 확인하고 노선을 전환했습니다.

2.2 프레네 공간에서의 속도 정의에 대한 오해와 정정

초기 설계 단계(모기비행게적 1234 버전 작성 당시)에는 미분기하학적 로컬 프레임에 대한 이해가 미흡하여, 미래 선회 기동 예측을 위한 피처로 법선 성분 속도 v_N 과 이중법선 성분 속도 v_B 를 명시적으로 계산하여 입력층에 주입하고자 시도했습니다.

그러나 프레네-세레(Frenet-Serret) 로컬 공간의 수학적 정의에 따르면, 비행선 상의 임의의 점에서의 속도 벡터 $\vec{v}$ 는 언제나 접선 벡터 $\vec{T}$ 방향과 나란해야 합니다.

$$\vec{v} = \frac{d\vec{r}}{dt} = \frac{ds}{dt} \vec{T}$$

따라서 로컬 프레임에서 속도를 표현하면 다음과 같이 고정됩니다.

$$v_T = |\vec{v}|, \quad v_N = 0, \quad \dots, \quad v_B = 0$$

즉, 접선 방향 이외의 속도 성분인 v_N, v_B 를 예측 피처로 포함하는 것은 수학적으로 존재하지 않는 물리량을 모델에 강제하는 모순이었음을 깨닫고 이를 폐기했습니다. 속도의 크기 자체를 다루는 방향으로 변수 결함을 수정했습니다.

3. 탐색적 데이터 분석 및 가설 검증 (EDA & Hypothesis Verification)

예측이 극도로 빗나가는 실패 구간을 파악하기 위해 구체적인 물리적 가설들을 설정하고 데이터로 이를 증명했습니다.

3.1 직전 가속도와 예측 오차 관계 분석 ($\vec{v} \cdot \vec{a}$)

물리적으로 속도와 가속도의 내적 $\vec{v} \cdot \vec{a}$ 는 직전 기동이 순수 가속(양수)인지 감속(음수)인지를 정량화합니다. 이 값을 기준으로 예측 성공 집단(True Positive, TP)과 실패 집단(False Positive, FP)이 어떻게 분포하는지 분석했습니다.

- 분석 결과, 가속 직후 등속을 유지하지 못하고 급격하게 선회로 기동이 꺾이는 영역에서 예측 실패(FP)가 대거 발생함을 정량적으로 파악했습니다.

3.2 법선-이중법선(NB) 평면 변위 가설 검증

"예측 에러가 큰 집단(FP)은 주 진행 방향인 접선 축에서 벗어나 법선(N) 및 이중법선(B) 축으로의 변위가 비정상적으로 클 것이다" 라는 가설을 세우고 바이올린 플롯으로 비교했습니다.

- 분석 결과 가설이 완전히 일치함을 확인했습니다. TP 그룹은 대부분의 변위가 바닥 평면에 가깝게 수렴한 반면, FP 그룹은 NB 평면상의 횡방향 변위가 폭발적으로 넓게 분산되어 있었습니다. 이는 오차의 주원인이 선회 기동에 있음을 뜻합니다.

3.3 속력 대비 선회 기동의 비율 분석

속력 $|\vec{v}|$ 의 크기에 따른 선회 기동 발생 비율을 분석했습니다.

- 분석 결과 모기가 고속 비행할 때 방향 전환(선회) 기동을 시도하는 비율이 저속 비행 시보다 지수적으로 높게 나타났습니다.
- 최종 딥러닝 모델이 고속 비행 구간에서 예측 오차가 유독 심하게 증가했던 핵심 물리적 이유가 바로 이 "고속 기동 시의 빈번한 선회 특성" 때문이었음을 규명했습니다.

3.4 a_N, a_T 시계열 가속도의 분리력

접선 가속도 a_T 와 법선 가속도 a_N 의 시계열 추이가 선회 기동과 등속 운동을 통계적으로 매우 깔끔하게 분류해낼 수 있음을 시각화로 확인했습니다. 선회 진입 시에는 a_N 이 급격하게 솟구치고 a_T 가 가라앉는 상보적인 패턴이 명확히 관찰되었습니다.

3.5 사잇각 ϕ 의 비선형성과 성능 기여

속도와 가속도 사이의 각도 ϕ 에 따라 미래 거동이 고도의 비선형적 관계를 띠는 것을 탐색했습니다.

$$\phi = \arccos \left(\frac{\vec{v} \cdot \vec{a}}{|\vec{v}| |\vec{a}|} \right)$$

수학적으로는 가속도 성분 비율인 $R(t) = a_N(t) / a_T(t)$ 와 완전히 동치 관계에 있는 기하학적 변수이지만, 인공신경망 모델에 ϕ 변수를 명시적으로 주입했을 때 비선형 공간 매핑이 원활해지며 최종 성능이 유의미하게 향상되는 결과를 얻었습니다.

4. 구현 코드 구조 및 데이터 증강 (Code Implementation)

본선 모델 학습을 위해 직접 설계하고 구현한 PyTorch 기반 코드의 핵심 메커니즘은 데이터 증강과 미분기하학 기반 피쳐 추출기, 그리고 심층 신경망 설계로 요약됩니다.

4.1 데이터 증강을 위한 슬라이딩 윈도우 (Sliding Window Augmentation)

시공간 내 모기 비행 패턴의 정상성을 극대화하여 한정된 데이터셋을 극복하고자, 11스텝 전체 궤적(인덱스 0부터 10) 내에서 연속적인 프레임을 슬라이딩 윈도우 방식으로 분할하여 여러 개의 학습 샘플을 추출하는 데이터 증강 기법을 설계했습니다.

- 윈도우 1: 인덱스 0부터 5까지의 데이터를 입력으로 취하고, $\Delta t = 80 \text{ ms}$ 뒤인 인덱스 7을 예측 타겟으로 설정

- 윈도우 2: 인덱스 1부터 6까지의 데이터를 입력으로 취하고, 인덱스 8을 예측 타겟으로 설정
- 윈도우 3: 인덱스 2부터 7까지의 데이터를 입력으로 취하고, 인덱스 9을 예측 타겟으로 설정
- 윈도우 4: 인덱스 3부터 8까지의 데이터를 입력으로 취하고, 인덱스 10을 예측 타겟으로 설정

이러한 슬라이딩 윈도우 데이터 증강 파이프라인을 구축함으로써 학습 샘플의 물리적 다양성을 확보하고, 관성 정보가 시계열 전체에 걸쳐 고르게 학습되도록 유도했습니다.

4.2 기하학적 피처 추출기 (MosquitoGeometryFeatureExtractor)

원시 위치 좌표 배열로부터 궤적의 기하학적 특성을 복원하기 위한 전처리 클래스를 직접 작성했습니다. 주요 기능은 다음과 같습니다.

- 속도 및 가속도 벡터 수치 계산: 위치 간 차분($\Delta x, \Delta y, \Delta z$)과 시간 간격(Δt)을 활용해 각 시점의 속도 벡터 $\vec{v}$ 와 가속도 벡터 $\vec{a}$ 를 산출합니다.
- 동역학적 특징 추출: 물리 피처인 속도 스칼라 $|\vec{v}|$, 속도와 가속도의 내적 $\vec{v} \cdot \vec{a}$, 접선 가속도 a_T , 법선 가속도 a_N , 궤적 곡률 κ , 그리고 내적각 ϕ 를 일괄 연산합니다.
- 결측치 및 예외 처리: 속도나 가속도가 극히 작아 기하학적 정의가 무너지는 특이점 분모에 수치적 안정성을 보장하기 위해 극소값($\epsilon = 10^{-8}$)을 가산하는 안전장치를 내포했습니다.

4.3 딥러닝 예측 모델 (Physics Network Layer)

피처 추출기를 통과한 기하 피처 텐서와 기존의 위치 시퀀스 정보를 다층 퍼셉트론(MLP) 및 심층 신경망 아키텍처에 순차적으로 결합하여 최종 미래 변위를 회귀하도록 설계했습니다.

각 레이어는 비선형 활성화 함수(ReLU)와 배치 정규화(Batch Normalization), 드롭아웃(Dropout)을 포함하여 고속 비행 중 발생하는 복잡한 움직임 패턴을 안전하게 수렴하도록 학습되었습니다.

5. 로드리게스 회전 공식 도입 및 최종 성과 (Rodrigues' Rotation & Top-26 Finish)

모델이 전역 좌표계(Global Coordinate)의 노이즈와 모기의 진행 방향 축 변화에 민감하게 반응하여 성능이 정체되자, 팀원이 프레네-세레 프레임과 전역 프레임 간의 변환 과정을 기하학적으로 일관되게 규정하는 로드리게스 회전 공식(Rodrigues' Rotation Formula)을 모델링 파이프라인에 이식했습니다.

5.1 로드리게스 회전 공식의 수학적 이식

로드리게스 회전 공식은 3차원 공간에서 회전축 벡터 $\vec{k}$ (크기가 1인 단위 벡터)를 기준으로 임의의 벡터 $\vec{v}$ 를 각도 θ 만큼 회전시킬 때 사용되는 공식입니다.

$$\vec{v}_{\text{rot}} = \vec{v} \cos \theta + (\vec{k} \times \vec{v}) \sin \theta + \vec{k} (\vec{k} \cdot \vec{v}) (1 - \cos \theta)$$

이를 모델의 오차 교정에 적용한 방식은 다음과 같습니다.

- 회전축의 정의: 모기가 비행 평면 내에서 방향을 전환할 때 발생하는 회전축은 로컬 프레임에서 비행 궤적 평면에 수직인 이중법선 벡터 $\vec{B}$ 로 고정할 수 있습니다.
- 로컬 평면 정렬: 모델이 전역 좌표계에서 제멋대로 방향을 추정하는 대신, 진행 방향($\vec{T}$)을 기준축으로 삼고 이중법선 방향($\vec{B}$)을 회전축 $\vec{k}$ 로 지정한 로컬 프레임 상에서 미래 변위 벡터를 우선 예측하게 합니다.
- 전역 복원: 예측된 로컬 변위 벡터를 로드리게스 회전 공식을 적용해 모기의 현재 순시 속도 벡터 각도만큼 전역 좌표계로 안정적으로 회전 변환($\vec{v} \rightarrow \vec{v}_{\text{rot}}$)하여 최종 전역 좌표 Y 를 계산합니다.

이 기하학적 정렬 처리를 통해 모델이 좌표축 방향성의 미세한 노이즈에 빠져 예측 궤적이 튀는 현상을 극적으로 억제할 수 있었습니다.

5.2 성능 변화 및 대회 최종 성과

- 기존 베이스라인 및 기하 피처 조합 모델 검증 스코어 (R-hit rate): 0.6926
- 로드리게스 회전 공식을 변환 파이프라인에 결합한 후 최종 앙상블 스코어: 0.6990
- 최종 성과: 검증 스코어의 확실한 개선을 바탕으로 리더보드 상위권으로 도약하여, 최종 26등이라는 우수한 성적으로 예측 대회를 마감했습니다.

6. 수학적/물리적 본질적 한계 및 좌절점 (The Ultimate Bottleneck)

성능을 최대치로 끌어올렸음에도 불구하고 분석을 통해 로컬 미분 공간의 정보만으로는 선회 기동의 방향성과 시점을 본질적으로 예측할 수 없다는 임계 장벽을 마주했습니다.

6.1 상태 공간의 중첩 및 조기 징후 상실

선회 기동으로 진입하기 직전 시점($t \rightarrow 0^+$)에서, 모기가 선회를 개시하는 궤적과 그대로 직선 비행을 유지하는 궤적의 물리적 상태 정보들을 비교 분석했습니다.

- 절망적인 중첩 분포: 선회 기동을 시작하는 그룹과 직선 운동을 유지하는 그룹의 직전 ϕ 값 및 가속도 성분의 평균적인 분포가 임계 구간 내부에서 완벽하게 중첩되어 있었습니다.

$$E[\phi_{t \rightarrow 0^+} | \text{Turn}] \approx E[\phi_{t \rightarrow 0^+} | \text{Straight}]$$
- 이는 모기가 방향을 꺾기 바로 직전까지 외부 관측자(센서 및 모델)에게 어떠한 물리적 예비 징후(Precursor)도 노출하지 않는다는 것을 의미합니다.
- 즉, $t=0$ 에서의 순간적인 v, a, j (속도, 가속도, 저크) 정보만으로 미래 궤적을 예측하려는 시도는 수학적으로 동일한 국소 정보로부터 서로 다른 두 미래 노이즈 분포(직진 대 선회)를 분리해내야 하는 불확정적인 역문제(ill-posed Inverse Problem)가 됩니다.

6.2 결론

- 프레네-세레 프레임이 회전하며 현재 시점의 정보를 흡수해 버리는 수학적 한계에 더해, 선회 기동 전후의 물리적 징후들이 상태 공간에서 고도로 중첩되어 있는 특성을 규명했습니다.
- 과거의 시계열 궤적 데이터만을 이용한 결정론적 회귀 모델로는 물리적 한계 영역 이상의 예측 정확도를 달성할 수 없음을 통계적으로 확인하였으며, 이 기하학적 불확정성 장벽을 확인하고 대회를 마무리하게 되었습니다.